

Expected Goals

(xG)



Autore	Matricola	E-mail
Francesco Pio Cataudo	0512116773	f.cataudo1@studenti.unisa.it
Francesco Santoro	0512117079	f.santoro42@studenti.unisa.it





SOMMARIO

In questo sommario abbiamo riassunto i punti cardine della nostra presentazione.

Partiremo dalla definizione formale del problema tramite le specifiche PEAS, per poi addentrarci nella parte più tecnica di preparazione dei dati e analisi dei risultati dei modelli che abbiamo testato.

01

Introduzione e Obiettivi

Lo scenario degli Expected Goals e le specifiche PEAS

02

Il Dataset e la Soluzione proposta

Analisi dei dati StatsBomb e definizione della pipeline.

03

Preprocessing & Feature Engineering

Pulizia dei dati e calcolo di Distanza e Angolo.

04

Modelli e Addestramento

Confronto tra Naïve Bayes, Decision Tree e Random Forest.

05

Analisi delle Prestazioni

Valutazioni tramite metriche, matrici di confusion e curve.

Introduzione e Obiettivi



Lo scenario degli Expected Goals

Il progetto affronta il task di classificazione binaria supervisionata per stimare la probabilità di successo di un tiro (Goal/No Goal). Le sfide principali sono lo sbilanciamento del dataset (pochi goal rispetto ai tiri) e la natura non lineare delle relazioni tra variabili spaziali ed esito.

Specifiche PEAS

Performance (P)

- *Massimizzazione di ROC-AUC e Average Precision.*
- *Robustezza su dati non visti e affidabilità delle probabilità stimate rispetto al benchmark StatsBomb.*

Enviroment (E)

- **Parzialmente osservabile:** *Mancano dati su portiere e difensori.*
- **Stocastico & Episodico:** *Ogni tiro è indipendente e l'esito non è deterministico.*

Actuators (A)

- **Modelli di ML:** *Naive Bayes, Decision Tree, Random Forest.*
- **Output:** *Probabilità continua $[0, 1]$ e grafici di valutazione (Confusion Matrix, Curve ROC/PR).*

Sensors (S)

- *Dati evento in formato JSON (StatsBomb).*
- *Coordinate spaziali (X, Y), variabili temporali e descrittive (pressione, parte del corpo).*

Il Dataset e la Soluzione Proposta



Il Dataset: StatsBomb Open Data

- **Sorgente:** Dati evento professionali in formato **JSON**.
- **Focus:** Analisi degli eventi di tipo "Shot" (tiri).
- **Variabile Target:** Binaria (1: Goal, 0: No Goal).
- **La sfida:** Dataset fortemente **sbilanciato** (solo l'11% dei tiri si trasforma in rete).

La Soluzione: Pipeline di Machine Learning

- **Paradigma:** Classificazione binaria supervisionata.
- **Pipeline End-to-End:**
 - **Acquisizione:** Caricamento e filtraggio degli eventi dai file JSON.
 - **Preprocessing:** Gestione dei valori mancanti e delle feature categoriche (One-Hot Encoding).
 - **Feature Engineering:** Trasformazione delle coordinate spaziali in Distanza e Angolo.
 - **Modellazione:** Addestramento di modelli (NB, DT, RF) con split Train/Test.

Preprocessing & Feature Engineering



Pulizia e Raffinamento (Cleaning)

- **Filtraggio:** Rimozione dei tiri con coordinate (x, y) mancanti.
- **Mapping Label:** Codifica binaria del target (1: Goal, 0: No Goal).
- **Selezione:** Focus su variabili spaziali, tecniche (parte del corpo, pressione) e temporali.

Strategia di Gestione dei Dati (Data Strategy)

- **Bilanciamento:** Scelta deliberata di **NON applicare downsampling**.
 - *Motivazione:* Preservare la distribuzione reale per ottenere stime xG calibrate e coerenti con la frequenza empirica dei goal.
- **Suddivisione Stratificata:** Split **80/20** (Train/Test) mantenendo la proporzione tra le classi per evitare distorsioni nella valutazione.

Trasformazione delle coordinate grezze in variabili fisiche (Feature Engineering Spaziale)

- **Distance:** Distanza euclidea dal centro della porta.
- **Angle:** Ampiezza dell'angolo di tiro rispetto ai due pali.

Modelli e Addestramento



Il processo di addestramento è automatizzato e garantisce la riproducibilità (Logica del Trainer)

- **Separazione Automatica:** Identificazione di feature numeriche e categoriche.
- **Pipeline Scikit-Learn:** Preprocessing (One-Hot Encoding) integrato per evitare incoerenze tra train e test.
- **Stratificazione:** Split **80/20** mantenendo la distribuzione reale delle classi (fondamentale per lo sbilanciamento dei goal).

Abbiamo testato tre approcci con livelli di complessità crescente (Modelli a Confronto)

- **Naive Bayes (Baseline):** Modello probabilistico semplice, basato sull'indipendenza delle feature.
- **Decision Tree:** Capacità di catturare relazioni non lineari tra distanza e angolo.
- **Random Forest:** Modello ensemble per migliorare la robustezza e ridurre l'overfitting.



Analisi delle Prestazioni



Valutazione dei Risultati e Confronto Modelli


Risultati Quantitativi (Set di Test: 17.605 eventi)

Modello	Accuracy	Precision (Goal)	Recall (Goal)	F1-score (Goal)	ROC-AUC
Naive Bayes	0.889	0.505	0.210	0.297	0.755
Decision Tree	0.834	0.278	0.307	0.292	0.604
Random Forest	0.897	0.613	0.210	0.313	0.777


Analisi Critica

- **Sbilanciamento:** L'accuratezza è alta per tutti (~90%) perché riflette la rarità dei goal (11%), ma le metriche chiave sono **ROC-AUC** e **Precision**.
- **Il Vincitore:** La **Random Forest** è il modello migliore. Con una Precision del **61.3%**, riduce drasticamente i falsi positivi (solo 260), offrendo stime xG molto più affidabili.
- **Baseline:** Il Naive Bayes si conferma una baseline solida, mentre il Decision Tree soffre di overfitting e scarsa capacità discriminante.


Comparazione grafica



Decision Tree: Il rischio dell'Overfitting
"Risulta il modello meno equilibrato. L'alto numero di Falsi Positivi (1561) indica una tendenza a sovrastimare la pericolosità dei tiri. La scarsa capacità di distinguere i veri negativi conferma una difficoltà nel generalizzare i pattern geometrici di distanza e angolo."




Naive Bayes: L'approccio Conservativo
Il modello mostra un comportamento prudente: riduce i Falsi Positivi (403), ma presenta un elevato numero di Falsi Negativi (1547). Tende a classificare quasi tutto come 'No Goal', perdendo molte occasioni reali ma mantenendo una discreta affidabilità nelle previsioni positive.



Random Forest: Il miglior Compromesso
È il modello più robusto: minimizza drasticamente i Falsi Positivi (solo 260), garantendo che, quando viene predetto un goal, la stima sia altamente affidabile. Pur mantenendo un numero di Falsi Negativi simile al Naive Bayes, offre la miglior capacità discriminante complessiva per il calcolo degli xG."




Comparazione grafica



ROC Curve (Receiver Operating Characteristic)

La curva ROC mostra la capacità discriminante dei modelli. La **Random Forest (AUC 0.777)** domina la baseline del Naive Bayes e del Decision Tree, dimostrando una superiore capacità di ordinare i tiri dai più pericolosi ai meno pericolosi. La distanza dalla diagonale (il classificatore casuale) evidenzia l'efficacia delle feature geometriche estratte.



Precision-Recall Curve

Questa è la metrica più severa e indicativa per il nostro dataset sbilanciato. La **Random Forest** mantiene una Precision sensibilmente più alta (Average Precision 0.381) rispetto agli altri modelli su quasi tutti i livelli di Recall. Questo conferma che il modello è solido nell'identificare i goal minimizzando il rumore di fondo dei tiri velleitari.



Conclusioni



Benchmark: Confronto con StatsBomb xG

- **Integrità del Modello:** Il valore *StatsBomb* xG è stato usato solo come riferimento esterno (nessun data leakage nel training).
- **Performance:**
 - **Random Forest:** ROC-AUC **0.777**
 - **StatsBomb xG:** ROC-AUC **0.832**
- **Considerazione:** Lo scarto è contenuto e atteso. L'elevata correlazione dimostra che il nostro modello ordina correttamente i tiri pur utilizzando un set di feature più semplificato rispetto al modello proprietario.

Sviluppi Futuri

- **Arricchimento Dati:** Estensione del dataset a più stagioni e competizioni per una maggiore generalizzazione.
- **Feature Contestuali:** Integrazione della posizione del portiere e della densità dei difensori (Dati *StatsBomb* 360).
- **Validazione e Calibrazione:** Implementazione della *Cross-Validation* temporale e affinamento della calibrazione delle probabilità rispetto alle frequenze reali.